

AI-Augmented Demand Forecasting 引擎設計 (v3.29)

本檔性質：跨時間序列分析 / 機器學習 / ERP / AI 四域之方法論文件，描述 erpilot v3.29 需求預測引擎之設計、實作與驗證。本版本接通 v3.25.10 → v3.28 規劃鏈之上游缺口：把「客戶手動輸入 MPS」改為「由歷史銷售自動預測 + LLM 增強」。

■ 前置文件：[MRP_ALGORITHM_DESIGN_ZH.md](#) (v3.25.10) / [THROUGHPUT_ACCOUNTING_DESIGN_ZH.md](#) (v3.28)

摘要 (Abstract)

erpilot 之前的 v3.25.10 → v3.28 規劃鏈，建立在 **MPS 由客戶手動輸入** 之假設上 —— 此假設使整條 IE/OR 鏈失去客觀性。本文敘述 v3.29 之需求預測引擎，整合 Croston (1972) 之 intermittent demand 經典演算法、Brown (1959) SES / Holt (1957) / Winters (1960) 之 exponential smoothing 家族、與 Hyndman & Koehler (2006) 之 MASE 指標自動選擇最佳方法。同步引入 Chatfield (1989) 之 regime change detection 作為 LLM 增強之觸發鉤子，當近期殘差超出 $\pm 2\sigma$ 即提示客戶以業務知識覆核。Makridakis et al. (2018, 2020) M4 / M5 大型實證競賽證明 classical 方法在多數時序仍勝過 deep learning，故本版本不引入 scipy / statsmodels / torch 相依，純 Python 實作 5 種方法保持輕量。30 個結構不變量測試全 pass，含 Hyndman-Koehler 2006 之 $MASE < 1 \Leftrightarrow$ 勝過 naive baseline 之經典性質。

關鍵字：需求預測、Croston、Holt-Winters、MASE、intermittent demand、regime change、LLM augmentation

1. 引言 (Introduction)

1.1 MPS 手動輸入之根本問題

v3.25.10 → v3.28 之 4 個 sprint 完成了 MRP-II、CLSP、TOC 三部曲。但所有計畫之起點 MPS 皆假設客戶能填出「W22 要生產 100 個 A 產品」這種數字。實務上：

- SMB 老闆沒有資料分析能力
- 銷售歷史有，但客戶不知道怎麼用
- 大部分零件是 intermittent demand (連續多週為 0，偶爾爆量) —— 直觀填數通常失準
- v3.27 之 explainability：「為什麼下週要這麼多 M6 螺絲？」最終總是回到 MPS，而 MPS 是客戶自己填的，erpilot 沒能力反問「你這個數字準嗎？」

1.2 為何不直接套 deep learning

Makridakis (2018) M4 競賽 結論驚人：在 100,000 個時序之大規模盲測中：

方法類別	平均 sMAPE	名次
Combine (多 classical 加權平均)	11.4%	第 1
Exponential smoothing + ARIMA	11.9%	第 2
deep learning (LSTM, MLP)	13.7%	倒數
Naive	14.3%	baseline

Makridakis (2020) M5 用 Walmart 銷售資料：classical 與 ML 表現接近，但 **classical** 更穩、更可解釋、訓練成本低。

對 SMB (短歷史、intermittent 為主)，classical 勝率更高。本版本因此選擇：

- ✓ Naive / Seasonal Naive baseline
- ✓ SES / Holt / Holt-Winters
- ✓ Croston (intermittent specialist)
- ✗ 暫不採 Prophet / N-BEATS / TFT (後續 sprint 評估)

1.3 為何 Croston 不可替代

Croston (1972, *J Op Res Soc* 23) 為「intermittent demand forecasting」奠定方法論。在 ERP 場景中：

- 工業螺絲：每週 0-0-0-50-0-0-30-0
- 機台零備件：3 個月一次
- 季節性禮品：1 年只在 11 月有訂單

SES 對此類資料永遠過度預測 (low-bias error 假設不成立)。Croston 拆解為：

```
forecast = (smoothed_demand_when_nonzero) / (smoothed_interval_between_demands)
```

並由 Syntetos & Boylan (2005) 證明 Croston 原始版本有正偏 (positive bias)，需 $(1 - \alpha/2)$ 修正。我們預設採用此修正。

2. 方法 (Methodology)

2.1 五種方法之數學形式

Naive： $\hat{y}_{t+k|t} = y_t \quad \forall k$

Seasonal Naive (season length L) :
$$\hat{y}_{t+k|t} = y_{t+L\lceil k/L\rceil}$$

****SES (Brown 1959)**** :
$$\begin{aligned} \ell_t &= \alpha \cdot y_t + (1-\alpha) \cdot \ell_{t-1} \\ \hat{y}_{t+k|t} &= \ell_t \end{aligned}$$

Holt (1957) linear trend :
$$\begin{aligned} \ell_t &= \alpha y_t + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\ b_t &= \beta (\ell_t - \ell_{t-1}) + (1-\beta) b_{t-1} \\ \hat{y}_{t+k|t} &= \ell_t + k \cdot b_t \end{aligned}$$

Holt-Winters (Winters 1960) additive :
$$\begin{aligned} \ell_t &= \alpha(y_t - s_{t-L}) + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\ b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta) b_{t-1} \\ s_t &= \gamma(y_t - \ell_t) + (1-\gamma) s_{t-L} \\ \hat{y}_{t+k|t} &= \ell_t + k \cdot b_t + s_{t-L+1+((k-1) \bmod L)} \end{aligned}$$

Croston (1972) + Syntetos-Boylan (2005) correction :
$$\hat{y}_{t+k|t} = \left(1 - \frac{\alpha}{2}\right) \cdot \frac{\tilde{Z}_t}{\tilde{X}_t}$$
 其中 $\tilde{Z}_t$ 為非零需求量之 SES · $\tilde{X}_t$ 為非零需求間隔之 SES。

2.2 精準度指標 (Hyndman & Koehler 2006)

MAPE (Mean Absolute Percentage Error) :
$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{|y_t|} \times 100\%$$
 問題 : $y_t = 0$ 時 undefined ; 對 over-forecast / under-forecast 不對稱。

sMAPE (symmetric) :
$$\text{sMAPE} = \frac{1}{n} \sum_{t=1}^n \frac{2|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|} \times 100\%$$
 範圍 [0, 200%] · 用於 M4 競賽。

MASE (Mean Absolute Scaled Error) —— 本系統之主要指標 :
$$\text{MASE} = \frac{\text{MAE}}{\text{forecast}} \cdot \frac{\text{MAE}_{\text{naive on training}}}{\text{naive on training}}$$
 性質 (Hyndman-Koehler 2006 證明) :

- Scale-free (跨序列可比)
- $y_t = 0$ 時仍 well-defined
- $\text{MASE} < 1 \Rightarrow$ 勝過 naive baseline
- M4 競賽用為主指標

2.3 預測區間 (Prediction Interval)

採 Hyndman & Athanasopoulos (2021) §5.5 之 residual bootstrap 簡化 :
$$PI_{t+k} = \hat{y}_{t+k} \pm z_{\alpha} \cdot \sigma \cdot \sqrt{k}$$
 其中 σ 為 in-sample 殘差之標準差 · $\sqrt{k}$ 反映「不確定性隨 horizon 累積」之直覺。

限制 : 假設殘差 iid normal ; 若殘差有自相關 / heteroscedasticity · 區間 mis-calibrated。

2.4 自動方法選擇

演算法 :

```

auto_select(history):
    if zero_fraction(history) > 0.4:          # intermittent 偵測
        candidates = [Naive, Croston]
    else:
        candidates = [Naive, SeasonalNaive, SES, Holt, HoltWinters]

    for each method in candidates:
        backtest_result = train_on(history[:-test_size]).forecast(test_size)
        record MASE

    return argmin(MASE) # 最佳方法

```

為何 intermittent 用更窄候選：依 Syntetos & Boylan (2005) 之結論，SES/Holt 對 intermittent 反應過劇（被零拉低 / 被尖峰拉高），實證上 MASE 較差。

2.5 Regime Change Detection (LLM 增強鉤子)

Chatfield (1989) §13：連續 k 期殘差超出 $\pm \theta \sigma$ 為「模型崩壞」之穩健指標。

erpilot 預設： $k=3, \theta=2.0$ （最近 3 期至少 2 期超出 2σ ）。

LLM 整合構想（v3.30 補）：當 `requires_llm_review = True` 時，prompt LLM 含：

1. 歷史時序
2. 預測值
3. 實際值
4. 業務 context（如客戶清單、季節、近期 SO 變動）

讓 LLM 用業務語言推測原因（如「客戶 X 砍單」「新法規上路」「對手降價」）並建議 qualitative 調整。所有調整必走 **ConfirmCard**（不可直接覆寫）。

3. 實作 (Implementation)

```
backend/app/services/demand_forecasting.py    (~600 行)
├─ ForecastMethod (Enum: NAIVE / SEASONAL_NAIVE / SES / HOLT / HOLT_WINTERS / CROSTON / AUTO)
├─ ForecastResult (dataclass: point_forecast / lower_95 / upper_95 / MAPE/sMAPE/MASE / diagnostic)
├─ BacktestResult (dataclass)
├─ RegimeChangeAlert (dataclass)
├─
├─ forecast_naive / forecast_seasonal_naive
├─ forecast_ses + _optimize_alpha_ses (grid search)
├─ forecast_holt
├─ forecast_holt_winters (additive)
├─ forecast_croston (with Syntetos-Boylan correction)
├─
├─ compute_mape / compute_smape / compute_mase
├─ prediction_intervals_residual
├─ backtest / run_forecast_method
├─ auto_select_method ← intermittent 偵測 + MASE 競賽
├─
├─ detect_regime_change ← LLM 增強鉤子
└─ forecast (top-level API)
```

4. 驗證 (Validation)

4.1 30 個結構不變量測試 (10 categories, 全 pass)

Category	測試數	涵蓋
1. Naive baseline	4	平直 / 空 / 季節旋轉 / fallback
2. SES (Brown 1959)	3	$\alpha=1$ 追蹤 / $\alpha\approx 0$ 平緩 / constant recovery
3. Holt (1957)	2	線性外推 / horizon 線性
4. Holt-Winters (1960)	2	完美週期復現 / short history fallback
5. Croston (1972)	4	全零 / rate recovery / 平直 / single event
6. 精準度指標	6	MAPE / sMAPE / MASE 經典性質
7. Auto-selection	2	intermittent 限制 + 選最低 MASE
8. 預測區間	2	隨 horizon 變寬 / 零殘差零寬
9. Regime change	2	偵測 / 不誤報
10. API 整合	3	完整 ForecastResult / horizon=0 / 顯式方法

4.2 結果

30/30 tests pass。Sprint 累計：442/442 smoke tests pass。

5. 限制與未來工作 (Limitations and Future Work)

議題	為何不做	將來方向
Modern ML (Prophet / N-BEATS / TFT)	M4 顯示 classical 仍具競爭力；ML 引入 torch/scipy 相依太重	v3.30+：可選相依，僅在 GPU 環境啟用
Time-series cross-validation	用 holdout 而非 rolling forecast origin	Hyndman 2021 §5.4 rolling CV
Hierarchical reconciliation	product / category / total 三層 forecast 不一致	Wickramasuriya, Athanasopoulos & Hyndman (2019) MinT
Auto-tuning of (α , β , γ)	目前 grid search α ； β γ 固定	Nelder-Mead / scipy.optimize 全參最佳化
Multiplicative seasonality	僅 additive	Holt-Winters multiplicative variant
External regressors (X-variables)	純 univariate	ARIMAX / regression with ARMA errors
State-space framework (ETS)	未整合	Hyndman, Koehler, Snyder & Grose (2002) statistical ETS
LLM augmentation 實際整合	規範定義完成 / API 未接	v3.30 補 prompt template + ConfirmCard 流程

5.1 邊界情況

1. 歷史 < 2 季節：HW 自動 fallback 到 Holt
2. 歷史全零：所有方法回傳 0
3. 單一非零事件：Croston 取均值 / 預期間隔
4. 負值需求 (如退貨)：未特別處理；建議客戶以「銷售淨額」為 input

6. 法律與責任聲明 (Legal Notice / 法律聲明)

⚠ 重要：統計預測之法律性質

本模組產生統計需求預測，所有預測皆具固有不确定性，不構成：

1. 未來需求之保證：點預測 (point forecast) 為演算法依歷史資料所估之期望值；實際需求可能與預測有顯著差異。預測區間 (PI) 為機率性近似，95% 區間不保證 95% 之事件落入率 (特別當資料

生成過程改變時)

2. 採購承諾之依據：客戶不可以本模組預測作為對供應商之採購承諾、對員工之加班排定、對客戶之交期保證之單一依據。重大決策應綜合考量市場條件、客戶具名 SO、業務情報等
3. 供應鏈爭議之證據：本模組之輸出不可作為「該預測值為 X，所以供應商應該...」之爭議證據。預測本質上是估計，不是契約承諾
4. 不可預見事件之預測：任何統計方法都無法預測：
 - 自然災害 (地震、洪水、颱風)
 - 政策變動 (關稅、法規、貿易戰)
 - 客戶經營狀況變動 (破產、合併、轉廠)
 - 競爭格局變化 (新進業者、技術突破)
 - Black Swan 事件 (Taleb 2007)

1. 演算法限制聲明

- 平穩性假設：所有方法假設資料生成過程在 forecast horizon 內穩定。Regime change 偵測為粗略指標，不能取代業務專業判斷
- $MASE < 1$ 並不保證決策正確：MASE 為「相對於 naive baseline」之表現指標；MASE 0.5 仍可能在絕對精度上不足以支撐重大決策
- 預測區間之 mis-calibration：殘差自相關、heteroscedasticity 時 PI 不準
- Auto-selection 之過度擬合：基於 holdout MASE 選方法可能在 holdout 上 lucky，未來不穩

2. LLM 增強層警告 (v3.30+ 啟用後適用)

當 `detect_regime_change` 觸發 LLM 覆核時：

- LLM 可能 hallucinate 業務原因 (編造客戶 / 競爭情境)
- LLM 之 qualitative adjustment 應僅供參考，不可自動覆寫預測
- 所有 LLM 建議必走 ConfirmCard (人類確認)
- LLM 提出之原因 (如「客戶 X 砍單」) 不構成對客戶 X 之事實陳述，避免誹謗風險

3. Croston / Intermittent demand 特殊聲明

Croston (1972) 假設非零需求事件為隨機過程。實務上：

- 若需求事件有結構性原因 (如月底盤點補單)，統計方法仍可能失準
- Syntetos-Boylan (2005) 之偏誤修正在 mean 上正確，但在 quantile 估計上仍有 bias
- 對於極稀疏資料 (如年度 1 次)，任何統計方法都不可靠 — 建議客戶以業務情報為主

4. 與 MPS 整合之責任

本模組可自動產生 MPS 建議值。但：

- MPS 之最終決策權應在生管主管，不可由演算法直接產生 production order

- 應走 **ConfirmCard** 流程：預測 → MPS 建議 → 主管覆核 → 確認 → 流入 MRP
- 重大決策（年度大宗料採購、capacity 投資）必須有額外覆核

5. 不擔保條款

於適用法律所允許之最大範圍內（to the maximum extent permitted by applicable law），erpilot 對下列事項不承擔責任：

- 因採用本模組預測所衍生之**過量採購 / 缺料停線**所造成之損失
- 因預測失準所造成之**客戶交期違約 / 違約金**
- 因 LLM 建議而產生之**錯誤業務判斷**
- 因 regime change 未及時偵測所造成之**規劃失誤**
- 因採用本模組之自動 MPS 而未經主管覆核所衍生之**任何後果**

6. 累積適用前置文件之聲明

本版本為 v3.25.10 → v3.28 規劃鏈之上游補完，因此前置文件 §6 之所有聲明於此累積適用。

建議實務做法

- 將預測視為「**起始建議值**」而非「**最終 MPS**」
- 每月對比實際 vs 預測，更新 method 選擇與參數
- 高金額 / 高風險料件（A 類）必須人工複核
- 在 PI 區間外之大量需求 → 主動聯繫客戶確認原因
- 保留 forecast accuracy 歷史記錄，作為與客戶 / 供應商議價之參考但**非法律證據**

7. 文獻 (References)

- [1] Brown, R. G. (1959). *Statistical Forecasting for Inventory Control*. McGraw-Hill. — SES 起源
- [2] Holt, C. C. (1957/2004 reprint). Forecasting seasonals and trends by exponentially weighted moving averages. *Int. J. Forecast.*, 20(1), 5-10. — 線性趨勢 ES
- [3] Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science*, 6(3), 324-342. — Holt-Winters 三變量
- [4] Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3), 289-303. — Croston 創始
- [5] Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *Int. J. Forecast.*, 21(2), 303-314. — Croston 偏誤修正
- [6] Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *Int. J. Forecast.*, 22(4), 679-688. — MASE 提出

[7] Hyndman, R. J., Koehler, A. B., Snyder, R. D., & Grose, S. (2002). A state space framework for automatic forecasting using exponential smoothing methods. *Int. J. Forecast.*, 18(3), 439-454. — ETS 統計框架

[8] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. — 開放教科書 (forecasting standard)

[9] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 Competition: Results, findings, conclusion and way forward. *Int. J. Forecast.*, 34(4), 802-808. — classical vs ML 大型實證

[10] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M5 accuracy competition: Results, findings, and conclusions. *Int. J. Forecast.*, 38(4), 1346-1364.

[11] Chatfield, C. (1989). *The Analysis of Time Series: An Introduction* (4th ed.). Chapman & Hall. — Regime change indicator

[12] Wickramasuriya, S. L., Athanasopoulos, G., & Hyndman, R. J. (2019). Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. *J. Am. Stat. Assoc.*, 114(526), 804-819. — Hierarchical reconciliation

[13] Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37-45. — Prophet (後續 sprint 評估)

[14] Oreshkin, B. N., Carpov, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *ICLR*. — N-BEATS

[15] Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *Int. J. Forecast.*, 37(4), 1748-1764. — TFT

[16] Taleb, N. N. (2007). *The Black Swan: The Impact of the Highly Improbable*. Random House. — 不可預見事件

8. 變更紀錄 (Changelog)

版本	日期	變更
v3.25.10	2026-05-20	MRP-II (基於手動 MPS)
v3.26 - v3.28	2026-05-20	CLSP / TOC trilogy (仍基於手動 MPS)
v3.29	2026-05-20	本版本：自動需求預測引擎 · 接通 MPS 上游缺口
將來 v3.30+	TBD	LLM 增強層整合 / Prophet 評估 / Hierarchical
將來 v3.31+	TBD	Rolling CV / ETS state-space / Multiplicative seasonality

最後更新：2026-05-20 (v3.29) 作者：erpilot 工程團隊 (含時序分析 / ML / ERP / AI 跨域學術方法論引用) 版本：1.0 English version : [DEMAND_FORECASTING_DESIGN_EN.md](#)